

模式识别

Lab1

姓名：郝裕玮

班级：计科 1 班

学号：18329015

目录

1 实验 5.2.....	3
1.1 题目内容.....	3
1.2 实验结果分析.....	4
2 实验 5.3.....	8
2.1 (a) 题.....	8
2.2 (b) 题.....	8
2.3 (c) 题.....	9
2.4 (d) 题.....	10
3 实验 6.6.....	11
3.1 (c) 题.....	11
3.2 (d) 题.....	13
3.3 补充题目.....	14

1 实验 5.2

1.1 题目内容

5.2 在本问题中, 我们将对 PCA 里平均向量的影响进行研究. 使用以下 Matlab / Octave 代码生成包含 5000 个样本的数据集并计算其特征向量. 如果我们忘记对每个样本进行减去平均向量的转换, 那么第一个特征向量 (即对应于最大特征值的那个特征向量) 和平均向量之间是否存在一定联系?

在将 scale 变量分别取下列集合中的值时, 观察这些向量的变化情况.

$\{1, 0.5, 0.1, 0.05, 0.01, 0.005, 0.001, 0.0005, 0.0001\}$.

如果 scale 产生变化, 正确的特征向量 (其中所有样本均移除平均向量) 是多少?

```
% set the random number seed to 0 for reproducibility
rand('seed', 0);
avg = [1 2 3 4 5 6 7 8 9 10];
scale = 0.001;
% generate 5000 examples, each 10 dim
data = randn(5000, 10) + repmat(avg*scale, 5000, 1);

m = mean(data); % average
m1 = m / norm(m); % normalized average

% do PCA, but without centering
[~, S, V] = svd(data);
S = diag(S);
e1 = V(:, 1); % first eigenvector, not minus mean vector
% do correct PCA with centering
newdata = data - repmat(m, 5000, 1);
[U, S, V] = svd(newdata);
S = diag(S);
new_e1 = V(:, 1); % first eigenvector, minus mean vector

% correlation between first eigenvector (new & old) and mean
avg = avg - mean(avg);
avg = avg / norm(avg);
e1 = e1 - mean(e1);
e1 = e1 / norm(e1);
new_e1 = new_e1 - mean(new_e1);
new_e1 = new_e1 / norm(new_e1);
corr1 = avg*e1
corr2 = e1'*new_e1
```

1.2 实验结果分析

(1) 运行代码可得特征向量结果如下所示：

```
-0.4461  
0.0441  
0.3508  
0.1448  
0.1831  
0.2297  
-0.4066  
-0.4544  
0.4363  
-0.0818
```

问：如果我们忘记对每个样本进行减去平均向量的转换，那么第一个特征向量(即对应于最大特征值的那个特征向量)和平均向量之间是否存在一定联系？

答：减去均值等同于坐标移动，这样就能把原始数据点的中心移到与原点重合，此举有利于很多表达，比如数据的协方差矩阵可以直接写成 $X \cdot X'$ ，若没有减去均值，则每两个特征之间都要进行 $(X - X \text{ 均值}) \cdot (Y - Y \text{ 均值})$ 运算，再组合成协方差矩阵。

从线性变换的本质来说，PCA 就是在线性空间做一个旋转（数据矩阵右乘协方差矩阵的特征向量矩阵），然后取低维子空间（实际上就是前 `n_components` 个特征向量张成的子空间）上的投影点来代替原本的点，以达到降维的目的。正因为只做了旋转，没有平移。所以我们要保证原本空间里的点是以原点为中心分布的，这就是我们对数据进行均值化的原因。

同时，只有原始数据点居中时，得到的均方误差才最小。

$$J_0(X_0) = \sum_{k=1}^n \|(X_0 - m) - (X_k - m)\|^2 = \sum_{k=1}^n \|X_0 - m\|^2 - 2(X_0 - m)^T \sum_{k=1}^n (X_k - m) + \sum_{k=1}^n \|X_k - m\|^2$$

上式中第二项为 0，第三项是与 X_0 无关的常数，所以 $X_0=m$ 时，均方误差最小。

在将 scale 变量分别取下列集合中的值时，观察这些向量的变化情况。

$\{1, 0.5, 0.1, 0.05, 0.01, 0.005, 0.001, 0.0005, 0.0001\}$ 。

如果 scale 产生变化，正确的特征向量（其中所有样本均移除平均向量）是多少？

正确的特征向量变化情况如下：

scale = 1：

-0.4276
-0.0416
0.1266
-0.0748
0.0566
0.3047
-0.0573
-0.2980
0.7161
-0.3047

scale = 0.5：

-0.1414
0.0002
-0.6894
0.5063
0.2303
0.1535
-0.3591
0.1714
0.0132
0.1151

scale = 0.1（见下页）：

0.3535
-0.0358
0.4541
0.1686
-0.0331
-0.1946
-0.6144
0.2266
0.0810
-0.4059

scale = 0.05:

-0.0916
0.3661
0.2400
-0.5166
-0.4447
0.2253
0.1581
0.3673
0.0461
-0.3500

scale = 0.01:

0.0668
0.1909
0.1472
0.1568
0.4924
-0.3451
-0.1428
0.0822
-0.7204
0.0720

scale = 0.005:

-0.1771
-0.2144
-0.4190
-0.1448
0.1175
0.7166
0.2723
-0.1719
-0.2075
0.2283

scale = 0.001 :

-0.4867
-0.0237
0.1764
0.4813
-0.1036
0.4908
-0.3004
-0.2664
-0.1917
0.2240

scale = 0.0005 :

-0.3416
0.4326
-0.2740
-0.6682
0.2720
0.1571
0.1168
0.2216
0.1113
-0.0276

scale = 0.0001 :

0.1459
0.6934
-0.1425
-0.2793
-0.0193
-0.5308
-0.0471
0.0640
0.2864
-0.1706


2 实验 5.3

使用 Matlab 或 GNU Octave 完成以下实验. 编程实现 PCA 和白化变换 —— 你可以使用 `eig` 或 `svd` 等函数, 但不能使用可直接完成本任务的函数 (例如 `princomp` 函数).

2.1 (a) 题

(a) 使用 `x=randn(2000,2)*[2 1;1 2]` 生成 2000 个样本, 每个样本都是二维的. 使用 `scatter` 函数画出这 2000 个样本.

```
x = randn(2000,2) * [2 1;1 2];  
figure(1);  
scatter(x(:,1), x(:,2));
```




2.2 (b) 题

(b) 对这些样本进行 PCA 变换并保留所有的 2 个维度. 使用 `scatter` 函数画出 PCA 后的样本.

```
x = randn(2000,2) * [2 1;1 2];  
mean_x = mean(x); % 均值  
cov_x = cov(x); % 协方差矩阵  
[ev,ed] = eigs(cov_x); % 特征向量  
[row,col] = size(x);  
u = repmat(mean_x , row, 1);
```



```
figure(1);
x1 = (x - u) * ev;
hold on;
scatter(x(:,1), x(:,2));
scatter(x1(:, 1), x1(:, 2));
```



2.3 (c) 题

(c) 对这些样本进行白化变换并保留所有的 2 个维度. 使用 `scatter` 函数画出 PCA 后的样本.

```
x = randn(2000,2) * [2 1;1 2];
mean_x = mean(x); % 均值
cov_x = cov(x); % 协方差矩阵
[ev,ed] = eigs(cov_x); % 特征向量
[row,col] = size(x);
u = repmat(mean_x , row, 1);
x1 = (x - u) * ev * inv(sqrt(ed));
hold on;
scatter(x(:,1), x(:,2));
scatter(x1(:, 1), x1(:, 2));
```

结果见下页:



2.4 (d) 题

(d) 如果在 PCA 变换中保留所有的维度, 为什么 PCA 是数据 (在进行平移之后) 的一个旋转? 这一操作为什么会有用?

答: PCA 的核心步骤有 2 步:

(1) 中心化: 原始数据集减去均值, 这里的矩阵减法相当于数据平移;

(2) 用前 k 个特征向量构成的矩阵乘原始矩阵实现矩阵降维。若保留所有维度, 则相当于将所有特征向量组成的矩阵乘原始矩阵, 这样的操作实际上就是基变换, 将矩阵进行旋转。

这一操作有用的原因: 向投影之后方差最大的维度进行投影, 投影后的数据能最大程度上的保留原始数据的信息。

3 实验 6.6

3.1 (c) 题

可在网址 http://docs.opencv.org/2.4/modules/contrib/doc/facerec/facerec_tutorial.html 找到一个关于人脸识别的 OpenCV 教程. 尝试理解教程中的每一行代码, 特别是那些关于 Eigenface (PCA) 和 Fisherface (FLD) 的代码. 在 ORL 数据集上运行该实验, 分析这些方法得到的识别结果之间的差异.

运行后结果如下:

Eigenface (PCA):

Predicted class = 39 / Actual class = 39.

Eigenvalue #0 = 2819989.11572

Eigenvalue #1 = 2062664.43241

Eigenvalue #2 = 1096663.64953

Eigenvalue #3 = 894183.32702

Eigenvalue #4 = 818967.15747


Eigenvalue #5 = 537972.44192

Eigenvalue #6 = 392438.01898

Eigenvalue #7 = 372326.54572

Eigenvalue #8 = 313616.90351

Eigenvalue #9 = 288570.19349



Fisherface (FLD):

Predicted class = 39 / Actual class = 39.

Eigenvalue #0 = 46343770.45151

Eigenvalue #1 = 12526.75725

Eigenvalue #2 = 2156.94929

Eigenvalue #3 = 1202.72304

Eigenvalue #4 = 643.75567

Eigenvalue #5 = 415.09794

Eigenvalue #6 = 364.10602

Eigenvalue #7 = 216.88946

Eigenvalue #8 = 160.48730

Eigenvalue #9 = 134.74498

Eigenvalue #10 = 87.77821

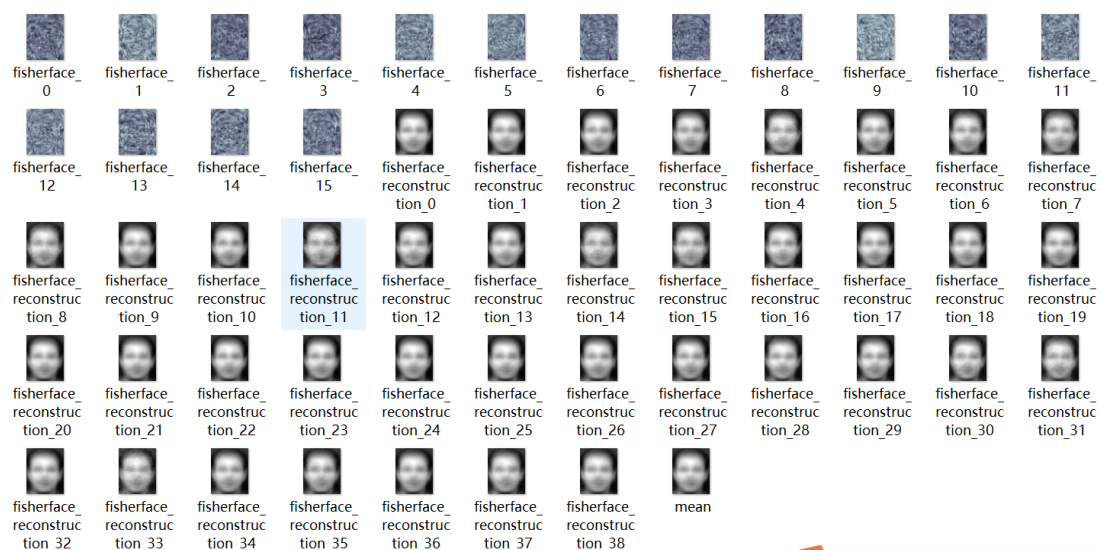
Eigenvalue #11 = 76.46510

Eigenvalue #12 = 49.96221

Eigenvalue #13 = 47.58930

Eigenvalue #14 = 42.38283

Eigenvalue #15 = 34.96763



Fisherfaces 算法和 Eigenfaces 算法有相同的地方，也有不相同的地方。相同：两者均可以对数据进行降维；两者在降维时均使用了矩阵特征分解的思想。不同：Fisherfac

es 是有监督的降维方法，而是 Eigenfaces 无监督的降维方法；Fisherfaces 除了可以用于降维，还可以用于分类。

Eigenfaces:

- 1、 训练图像；
- 2、 求出平均脸；
- 3、 获得特征子脸；
- 4、 进行图像重构；
- 5、 寻找相似度高的人脸图像。

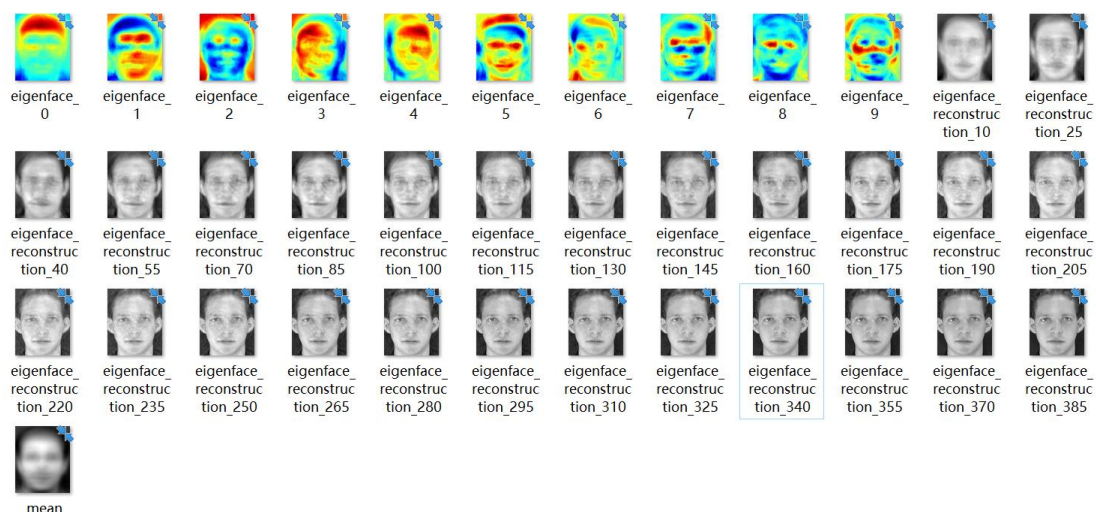
Fisherfaces:

- 1、 获得人脸图像数据，然后求出人脸的均值；
- 2、 观察各个人脸的特征值；
- 3、 进行人脸鉴定，观察人脸特征，判断是否是个人；
- 4、 最后进行人脸识别。

3.2 (d) 题

在 Eigenface 实验中, 你可以使用 eigenfaces (特征脸, 即特征向量) 来重构近似的人脸图像. 修改 OpenCV 教程中的源代码, 并使用不同数量的 eigenfaces 来观察可视化的结果. 如果你希望从 eigenfaces 中重构的人脸看上去与原始输入的人脸图像之间难以区分, 那么你需要多少张 eigenfaces?

因为难以区分是主观标准，所以经过个人实验对比，需要 10 张 eigenfaces 即可。



3.3 补充题目

将 PCA 和 FLD 中的特征向量 resize 成原图尺寸，并显示前 10 个 Eigenface 和 Fisherface。

(1) 对于 Eigenface:

源代码:

```
for(int num_components = min(W.cols, 10); num_components <
min(W.cols, 300); num_components+=15)
```

修改为:

```
for(int num_components = min(W.cols, 10); num_components < W.cols;
num_components+=15)
```

(2) 对于 Fisherface:

源代码:

```
for(int num_component = 0; num_component < min(16, W.cols);
num_component++) {
```

修改为:

```
for(int num_component = 0; num_component < W.cols; num_component++) {
```

展示结果如下:

